FACULTAD DE MEDICINA
UNIVERSIDAD DE CHILE

Alineamiento de lecturas y llamado de variantes

RICARDO A. VERDUGO, Ph.D.

Departamento de Oncología Básico Clínica
Facultad de Medicina, U. de Chile

Noviembre de 2026

GENOMED-Lab
http://genomed.med.uchile.cl

1

Advertencia

- Los flujos de trabajo son complejos, compuesto de muchas etapas con varias alternativas de argumentos en cada uno
- Existen muchas (posiblemente infinitas) formas de realizar los análisis que veremos en esta clase
- Si bien existene “mejores prácticas”, éstas requieren ser adaptadas a cada situación, lo cual siempre es reponsablidad de analista.
- El objetivo de la clase no es revisar todas las alternativas ni recomendar alguna en particular, sino **entregar los elementos teóricos para que usted pueda tomar deciciones informadas** y encontrar información adicional útil.

2

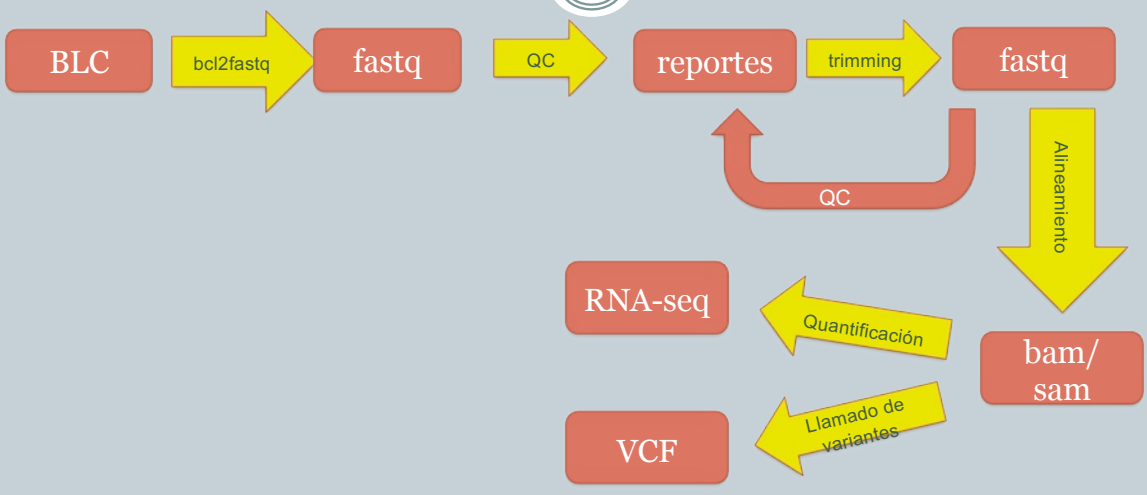
Temas a cubrir

Parte I: Alineamiento

1. Flujos de trabajo NGS con alineamiento
2. Qué es un alineamiento de secuencias
3. Algunos algoritmos
4. Control de calidad del alineamiento

3

Algunos flujos de ánalisis que requieren alineamiento



4

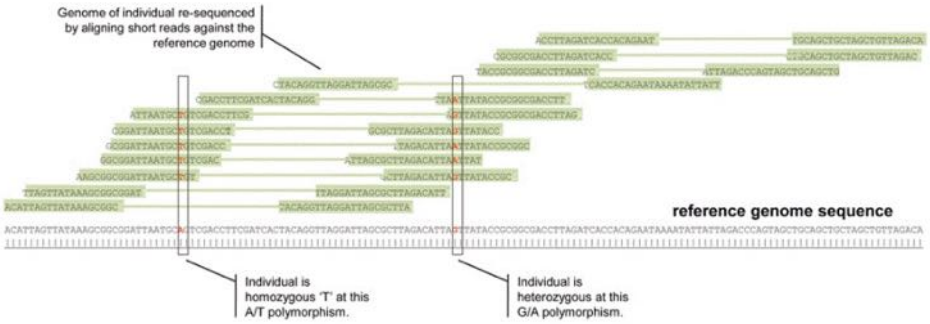
Raw sequencing data: Fastq format

```
@IL31_4368:1:1:996:8507/2
TCCCTTACCCCCAAGCTCCATACCCTCCTAATGCCCACACCTCTTACCTTAGGA
+
FFCEFFFEEFFFFFFFEFFEFFFEFCFC<EEFEFFFCEFF<;EEFF=FEE?FCE
@IL31_4368:1:1:996:21421/2
CAAAAACTTTCACTTTACCTGCCGGGTTTCCCAGTTTACATTCCACTGTTTGAC
+
>DBDDB,B9BAA4AAB7BB?7BBB=91;+*@;5<87+*=/*@@?9=73=.7)7*
@IL31_4368:1:1:997:10572/2
GATCTTCTGTGACTGGAAGAAAATGTGTTACATATTACATTTCTGTCCCCATTG
+
E?=EECE<EEEE98EEEEAEEBD??BE@AEAB><EEABCEEDEC<<EBDA=DEE
@IL31_4368:1:1:997:15684/2
CAGCCTCAGATTCAGCATTCTCAAATTCAGCTGCGGCTGAAACAGCAGCAGGAC
+
EEEEDEEE9EAEEDEEEEEEEEEECEEAAEEDEE<CD=D=*BCAC?;CB,<D@,
@IL31_4368:1:1:997:15249/2
AATGTTCTGAAACCTCTGAGAAAGCAAATATTTATTTTAATGAAAAATCCTTAT
+
EDEEC;EEE;EEE?EECE;7AEEEEEE07EECEA;D6D>+EE4E7EEE4;E=EA
@IL31_4368:1:1:997:6273/2
ACATTTACCAAGACCAAAGGAAACTTACCTTGCAAGAATTAGACAGTTCATTTG
+
EEAAFFFEEFEFCFAFFAFCCFFEFEF>EFFFFB?ABA@ECEE=<F@DE@DDF;
@IL31_4368:1:1:997:1657/2
CCCACCTCTCTCAATGTTTTCCATATGGCAGGGACTCAGCACAGGTGGATTAAT
(...)
```

- Instrument serial #
- Lane
- Swath
- X coord
- Y coord
- Read direction

5

Alineamiento de lecturas de secuencias



6

Preguntas clave

1. ¿Qué queremos alinear?
2. ¿Cómo valoraremos un buen alineamiento?
3. ¿Cómo encontramos el mejor alineamiento?

7

¿Qué queremos alienar?

- **alineación global:** encuentre la mejor coincidencia de ambas secuencias en su totalidad
- **alineación local:** encuentra la mejor coincidencia de subsecuencias
- **alineación semi-global:** encuentre la mejor coincidencia sin penalizar las brechas en los extremos de la alineación

8

El espacio de posibles alineamientos

- Estos son algunos posibles alineamientos de las palabras ELV y VIS

```
ELV        -ELV       --ELV      ELV-
VIS        VIS-       VIS--      -VIS

E-LV       ELV--      EL-V
VIS-       --VIS      -VIS
```

9

¿Cómo valoraremos un buen alineamiento?

- Función de penalización de espacios (gaps)
  - *w(k) = costo de un espacio de largo k en la secuencia*
  - La más simple es una función lineal: w(k)= g×k
  - *g* es una constante
- Matriz de substitución
  - *s(a, b)* indica la puntuación de alinear el carácter *a* con el carácter *b*
  - La más simple es *s(a, b)={+1 si a=b, -1 si a≠b}*

	A	G	C	T
A	1	-1	-1	-1
G	-1	1	-1	-1
C	-1	-1	1	-1
T	-1	-1	-1	1

10

Valoración de un alineamiento

- El puntaje de una alineación es la suma de los puntajes para pares de caracteres alineados más los puntajes de las brechas
- ejemplo: dada el siguiente alineamiento

```
VAHV---D--DMPNALSALSDLHAHKL
AIQLQVTGVVVTDATLKNLGSVHVSKG
```

El puntaje se calcula:

s(V,A) + s(A,I) + s(H,Q) + s(V,L) + 3g + s(D,G) + 2g ...

11

¿Cómo encontramos el mejor alineamiento?

- ¿Cuál sería el mejor alineamiento de estas dos cadenas de caracteres?

```
T H A T T I N H A T
C A T I N H A T
```

1. Aproximación ingenua
   1. Enumerar todas las posibles subcadenas de cada cadena
   2. Compararlas mediante un puntaje
   3. Elegir la pareja de mayor puntaje

      Tiempo requerido: $O(n^2)$ $O(n^2) = O(n^4)$

Posibles alineamientos

$$\binom{2n}{n} = \frac{(2n)!}{(n!)^2} \approx \frac{2^{2n}}{\sqrt{\pi n}}$$

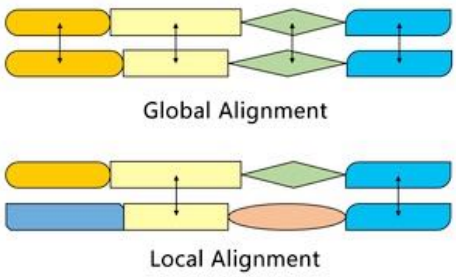
12

Solución por programación dinámica

- **Programación dinámica**: resuelva una instancia de un problema aprovechando las soluciones para subpartes del problema
  - reducir el problema de la mejor alineación de dos secuencias a la mejor alineación de todos los prefijos de las secuencias
  - Evitar recalcular las puntuaciones ya consideradas.
- Utilizado por primera vez en alineación por Needleman & Wunsch, Journal of Molecular Biology, 1970

13

Alineamiento Global vs Local



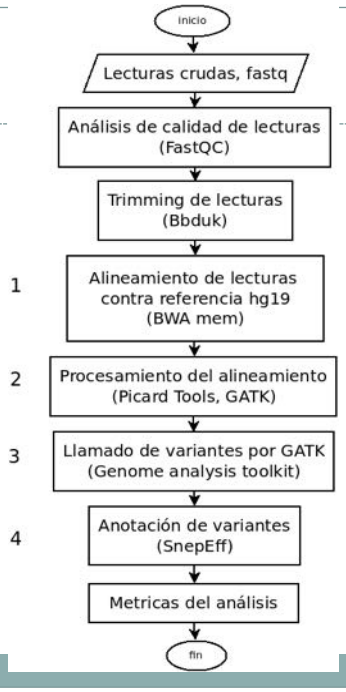
14

Alineador BWA

Burrows–Wheeler Aligner (BWA) S/W Package

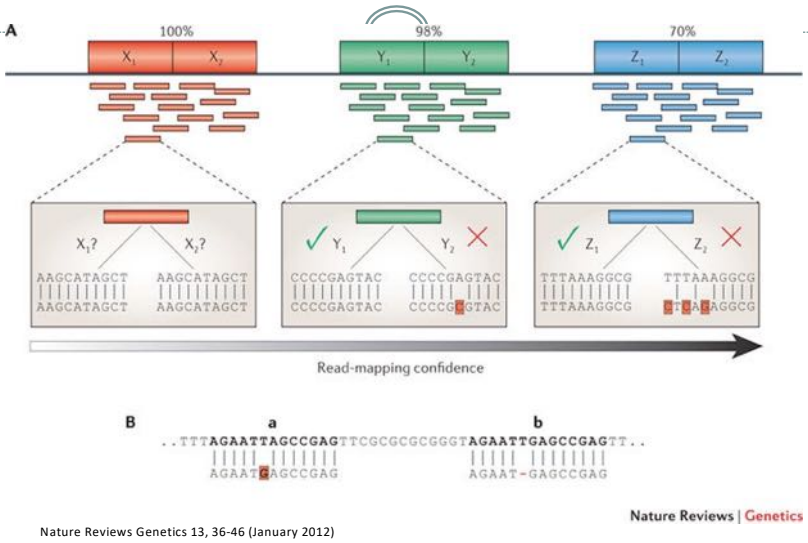
- Use Burrows-Wheeler Transform to "index" the human genome and allow memory-efficient and fast string matching between sequence read and reference genome.
- BWA: Short-read algorithm, alter the read sequence such that it matches the reference exactly.
- BWA-SW: Long-read algorithm, sample reference subsequences and perform Smith-Waterman alignment between the subsequences and the read.
- BWA-MEM: - Similar features to BWA-SW
  - Long-read alignment
  - Seed and extend with SW
  - Finds larger gaps
  - Faster! Generally supersedes BWA-SW

15



16

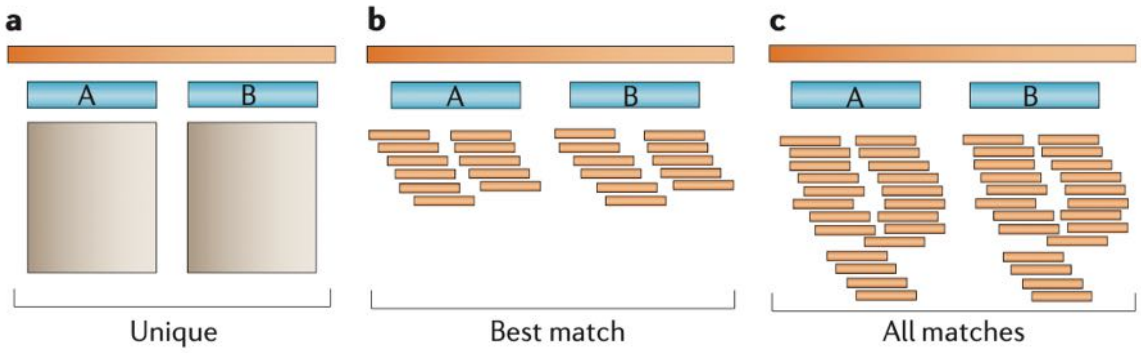
Alineamiento en Regiones Repetidas



Nature Reviews Genetics 13, 36-46 (January 2012)
doi:10.1038/nrg3117

17

Estrategias de reporte para lecturas con más de un mapeo (multi-reads)



18

Formato Sequence Alignment Map (SAM)



```
@HD     VN:1.0  SO:coordinate
@SQ     SN:chr20        LN:64444167
@PG     ID:TopHat       VN:2.0.14       CL:/srv/dna_tools/tophat/tophat -N 3 --read-edit-dist 5 --read-rea
lign-edit-dist 2 -i 50 -I 5000 --max-coverage-intron 5000 -M -o out /data/user446/mapping_tophat/index/chr
20 /data/user446/mapping_tophat/L6_18_GTGAAA_L007_R1_001.fastq
HWI-ST1145:74:C101DACXX:7:1102:4284:73714        16      chr20   190930  3       100M    *       0       0
       CCGTGTTTAAAGGTGGATGCGGTCACCTTCCCAGCTAGGCTTAGGGATTCTTAGTTGGCCTAGGAAATCCAGCTAGTCCTGTCTCTCAGTCCCCCCTCT
C    BBDCCDDCCDDDDCDDDDDDCDCCCDBC?DDDDDDDDDDDDDDDCCDCDDDDDDDDDDCCCCEDDDC?DDDDDDDDDDDDDDDDDDDDDDBDHFFFFDC@@
    AS:i:-15        XM:i:3  XO:i:0  XG:i:0  MD:Z:55C20C13A9 NM:i:3  NH:i:2  CC:Z:=  CP:i:55352714   HI:i:0
HWI-ST1145:74:C101DACXX:7:1114:2759:41961        16      chr20   193953  50      100M    *       0       0
       TGCTGGATCATCTGGTTAGTGGCTTCTGACTCAGAGGACCTTCGTCCCCTGGGGCAGTGGACCTTCCAGTGATTCCCCTGACATAAGGGGCATGGACGA
G    DCDDDDEDDDDDDDCDDDDDDDCCCDDDCDDDDDEEC>DFFFEJJJJJIGJJJJIHGBHHGJIJJJJJJGJJJIJJJJJIHJJJJJJHHHHHFFFFFCCC
    AS:i:-16        XM:i:3  XO:i:0  XG:i:0  MD:Z:60G16T18T3 NM:i:3  NH:i:1
HWI-ST1145:74:C101DACXX:7:1204:14760:4030        16      chr20   270877  50      100M    *       0       0
       GGCTTTATTGGTAAAAAAGGAATAGCAGATTTAATCAGAAATTCCCACCTGGCCCAGCAGCACCAACCAGAAAGAAGGGAAGAAGACAGGAAAAAACCA
C    DDDDDDDDDCCDDDDDDDDDDEEEEEEEFFFEFFEGHHHHFGDJJIHJJIJIJJJJIIIIGGFJJIHIIIIIJJJJJJIGHHFAHGFHJHFGGHFFFDD@BB
    AS:i:-11        XM:i:2  XO:i:0  XG:i:0  MD:Z:0A85G13    NM:i:2  NH:i:1
HWI-ST1145:74:C101DACXX:7:1210:11167:8699        0       chr20   271218  50      50M4700N50M     *       0
       0       GTGGCTCTTCCACAGGAATGTTGAGGATGACATCCATGTCTGGGGTGCACTTGGGTCTCCGAAGCAGAACATCCTCAAATATGACCTCTCG
accepted_hits.sam
```

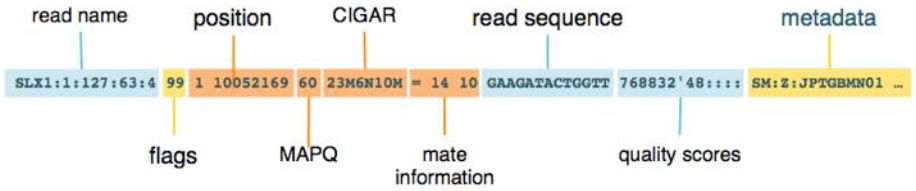
19

Tag	Description
@HD	The header line. The first line if present.
VN*	Format version. *Accepted format:* `/^[0-9]+\.[0-9]+$/`.
SO	Sorting order of alignments. *Valid values:* **unknown** (default), **unsorted**, **queryname** and **coordinate**. For coordinate sort, the major sort key is the RNAME field, with order defined by the order of @SQ lines in the header. The minor sort key is the POS field. For alignments with equal RNAME and POS, order is arbitrary. All alignments with '*' in RNAME field follow alignments with some other value but otherwise are in arbitrary order.
GO	Grouping of alignments, indicating that similar alignment records are grouped together but the file is not necessarily sorted overall. *Valid values:* **none** (default), **query** (alignments are grouped by QNAME), and **reference** (alignments are grouped by RNAME/POS).
@SQ	Reference sequence dictionary. The order of @SQ lines defines the alignment sorting order.
SN*	Reference sequence name. Each @SQ line must have a unique SN tag. The value of this field is used in the alignment records in RNAME and RNEXT fields. Regular expression: `[!-)+-<>-~][!-~]*`
LN*	Reference sequence length. *Range:* $[1,2^{31}-1]$
AS	Genome assembly identifier.
M5	MD5 checksum of the sequence in the uppercase, excluding spaces but including pads (as '*'s).
SP	Species.
UR	URI of the sequence. This value may start with one of the standard protocols, e.g http: or ftp:. If it does not start with one of these protocols, it is assumed to be a file-system path.
@RG	Read group. Unordered multiple @RG lines are allowed.
ID*	Read group identifier. Each @RG line must have a unique ID. The value of ID is used in the RG tags of alignment records. Must be unique among all read groups in header section. Read group IDs may be modified when merging SAM files in order to handle collisions.
CN	Name of sequencing center producing the read.
DS	Description.
DT	Date the run was produced (ISO8601 date or date/time).
FO	Flow order. The array of nucleotide bases that correspond to the nucleotides used for each flow of each read. Multi-base flows are encoded in IUPAC format, and non-nucleotide flows by various other characters. *Format:* `/\*|[ACMGRSVTWYHKDBN]+/`
KS	The array of nucleotide bases that correspond to the key sequence of each read.
LB	Library.
PG	Programs used for processing the read group.
PI	Predicted median insert size.
PL	Platform/technology used to produce the reads. *Valid values:* **CAPILLARY**, **LS454**, **ILLUMINA**, **SOLID**, **HELICOS**, **IONTORRENT**, **ONT**, and **PACBIO**.
PM	Platform model. Free-form text providing further details of the platform/technology used.
PU	Platform unit (e.g. flowcell-barcode.lane for Illumina or slide for SOLiD). Unique identifier.
SM	Sample. Use pool name where a pool is being sequenced.
@PG	Program.
ID*	Program record identifier. Each @PG line must have a unique ID. The value of ID is used in the alignment PG tag and PP tags of other @PG lines. PG IDs may be modified when merging SAM files in order to handle collisions.
PN	Program name
CL	Command line

20

Archivo SAM: registros

HEADER containing metadata (sequence dictionary, read group definitions etc)
RECORDS containing structured read information (1 line per read record)



21

CIGAR

```
RefPos:     1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19
Reference:  C  C  A  T  A  C  T  G  A  A  C  T  G  A  C  T  A  A  C
Read:       ACTAGAATGGCT

Aligning these two:
RefPos:     1  2  3  4  5  6  7     8  9 10 11 12 13 14 15 16 17 18 19
Reference:  C  C  A  T  A  C  T     G  A  A  C  T  G  A  C  T  A  A  C
Read:                   A  C  T  A  G  A  A     T  G  G  C  T

With the alignment above, you get:
POS: 5 CIGAR: 3M1I3M1D5M
```

Cada operación está representada por un número seguido de una letra que especifica el tipo de evento:

- M representa coincidencias o diferencias,
- I inserciones en la lectura,
- D deleciones respecto a la referencia,
- N saltos (por ejemplo, intrones en datos de ARN-seq),
- S secuencias suavizadas (soft clipping),
- H secuencias recortadas (hard clipping).

22

Integrative Genomic Viewer



http://software.broadinstitute.org/software/igv/

23

¿Qué mirar en una visualización de alineamiento?

- Cobertura en la región de interés
- Posible sesgo de variantes entre R1 y R2 o por hebra (strand bias)
- Variantes que estén en los extremos
- INDELs en los extremos
- Sustituciones alrededor de los INDELs (realizar realineamiento local)

24

Métricas básicas de calidad

- % de lecturas mapeados
- % de lecturas únicamente mapeados
- % de lecturas efectivamente mapeados (luego de eliminar duplicados)
- Profundidad promedio (x)
- Cobertura (% de la región blanco que fue cubierta con lecturas)
- Calidad de mapeo (QMAP para cada lectura) -> tasa de error
- Distribución de tamaños de inserto (para librerías pareadas)
- % de lecturas en el blanco (*on target)*
- Enriquecimiento de región blanco (*on target)*

25

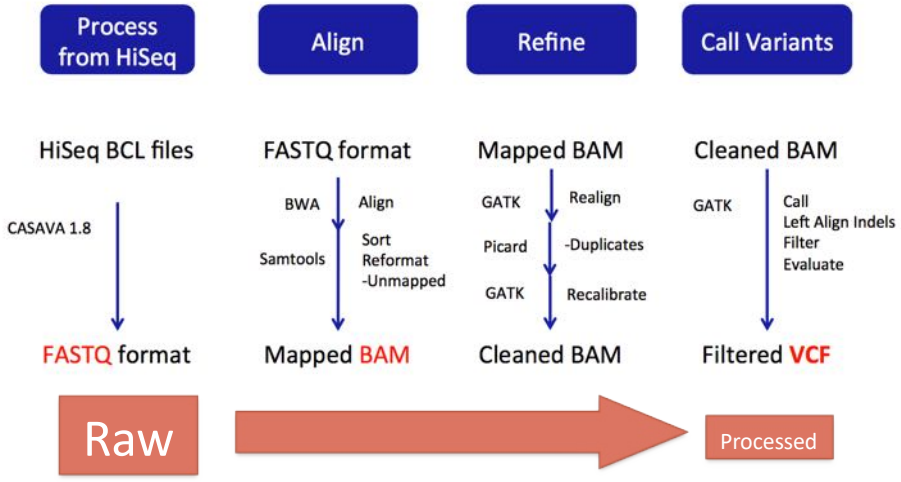
Temas a cubrir

Parte II: Llamado de variantes

1. Workflow
2. Archivos SAM (y BAM)
3. Mejores prácticas de GATK
4. Base quality score recalibration (BQSR)
5. Variant Call Format (VCF)
6. Anotación de Variantes

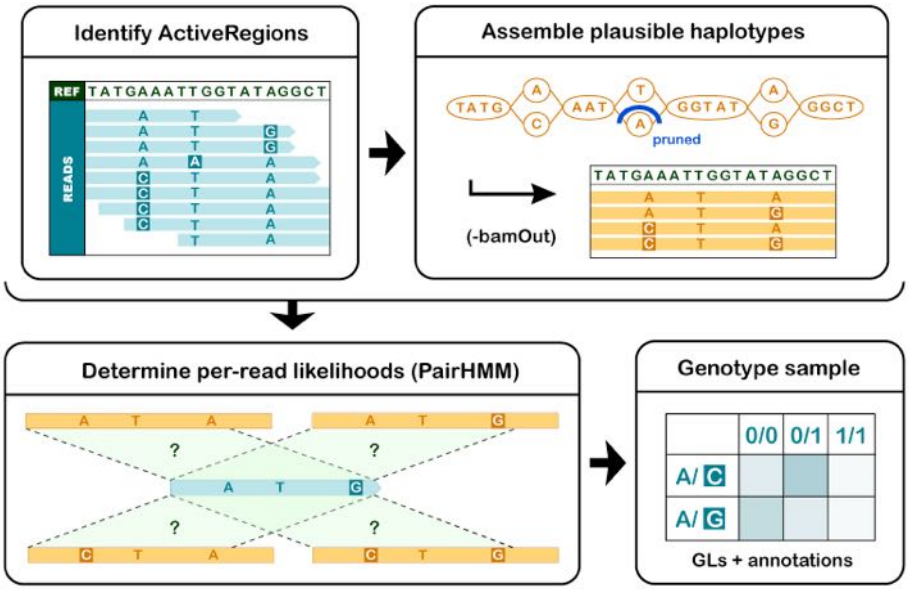
26

NGS data files

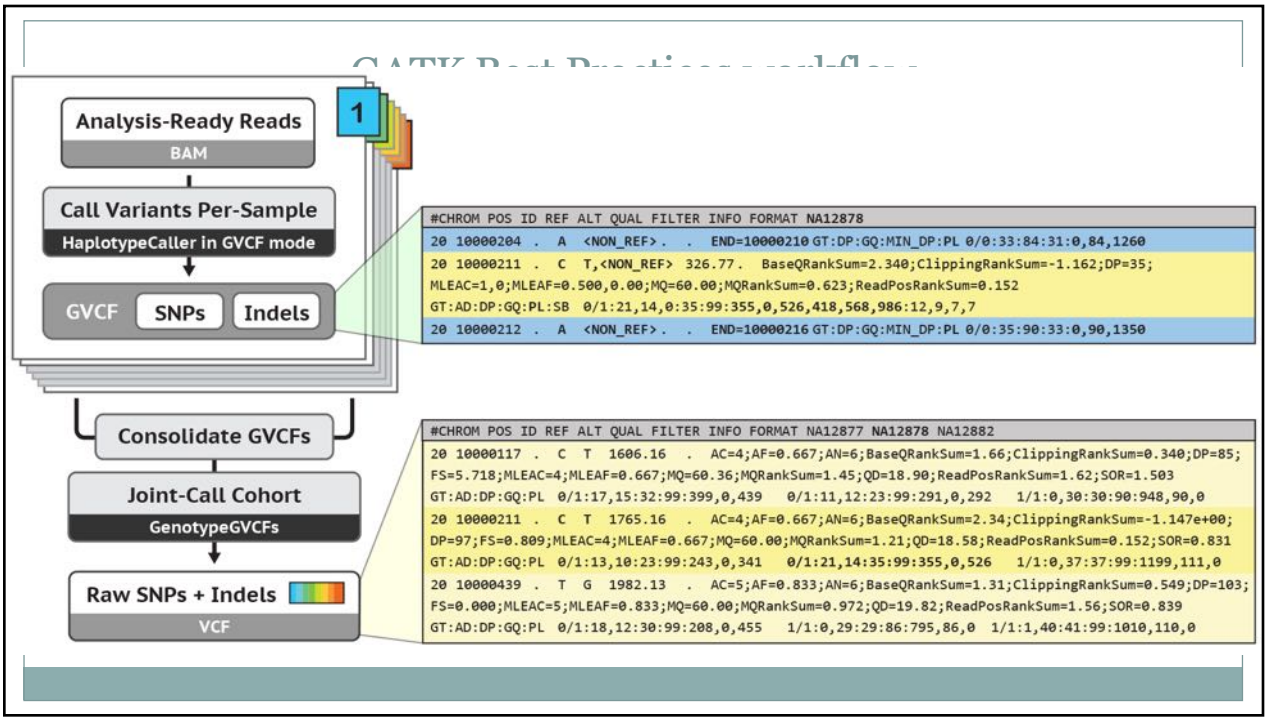


27

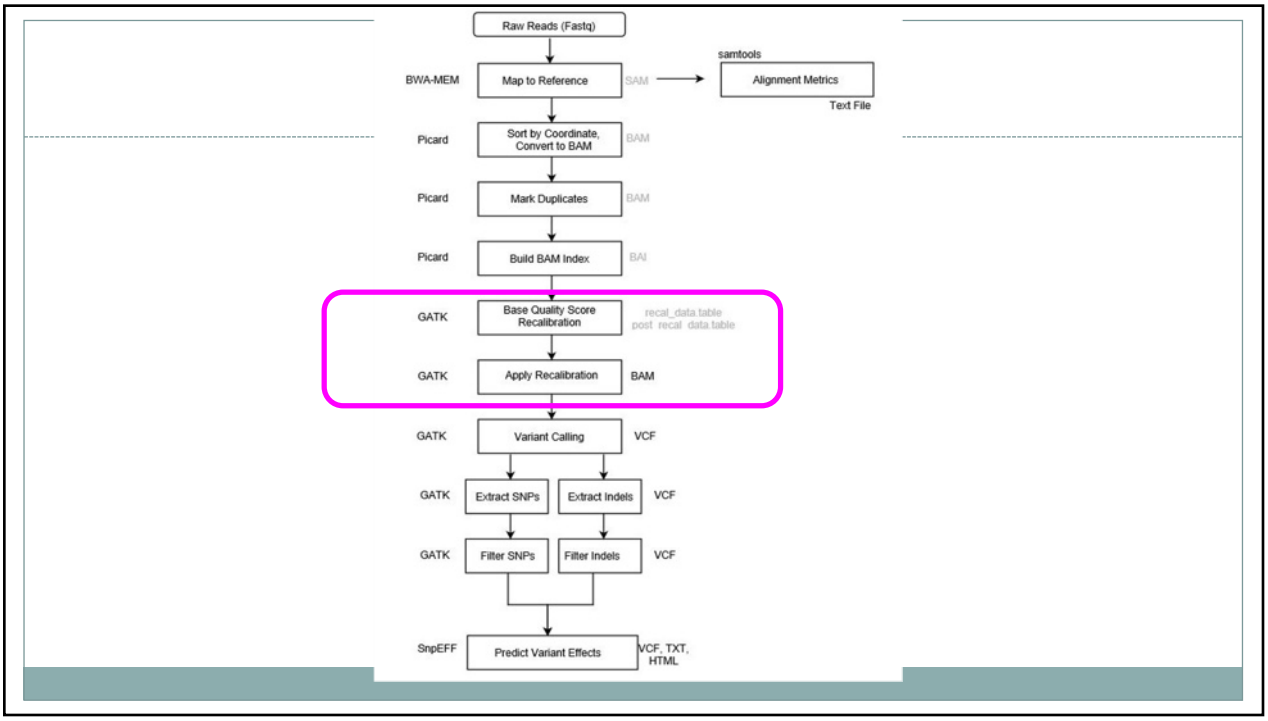
Llamado de Variantes: GATK HaplotypeCaller



28


Analysis-Ready Reads
BAM
1
Call Variants Per-Sample
HaplotypeCaller in GVCF mode
GVCF
SNPs
Indels
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT NA12878
20 10000204 . A <NON_REF> . . END=10000210 GT:DP:GQ:MIN_DP:PL 0/0:33:84:31:0,84,1260
20 10000211 . C T,<NON_REF> 326.77 . BaseQRankSum=2.340;ClippingRankSum=-1.162;DP=35;
MLEAC=1,0;MLEAF=0.500,0.00;MQ=60.00;MQRankSum=0.623;ReadPosRankSum=0.152
GT:AD:DP:GQ:PL:SB 0/1:21,14,0:35:99:355,0,526,418,568,986:12,9,7,7
20 10000212 . A <NON_REF> . . END=10000216 GT:DP:GQ:MIN_DP:PL 0/0:35:90:33:0,90,1350
Consolidate GVCFs
Joint-Call Cohort
GenotypeGVCFs
Raw SNPs + Indels
VCF
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT NA12877 NA12878 NA12882
20 10000117 . C T 1606.16 . AC=4;AF=0.667;AN=6;BaseQRankSum=1.66;ClippingRankSum=0.340;DP=85;
FS=5.718;MLEAC=4;MLEAF=0.667;MQ=60.36;MQRankSum=1.45;QD=18.90;ReadPosRankSum=1.62;SOR=1.503
GT:AD:DP:GQ:PL 0/1:17,15:32:99:399,0,439 0/1:11,12:23:99:291,0,292 1/1:0,30:30:90:948,90,0
20 10000211 . C T 1765.16 . AC=4;AF=0.667;AN=6;BaseQRankSum=2.34;ClippingRankSum=-1.147e+00;
DP=97;FS=0.809;MLEAC=4;MLEAF=0.667;MQ=60.00;MQRankSum=1.21;QD=18.58;ReadPosRankSum=0.152;SOR=0.831
GT:AD:DP:GQ:PL 0/1:13,10:23:99:243,0,341 0/1:21,14:35:99:355,0,526 1/1:0,37:37:99:1199,111,0
20 10000439 . T G 1982.13 . AC=5;AF=0.833;AN=6;BaseQRankSum=1.31;ClippingRankSum=0.549;DP=103;
FS=0.000;MLEAC=5;MLEAF=0.833;MQ=60.00;MQRankSum=0.972;QD=19.82;ReadPosRankSum=1.56;SOR=0.839
GT:AD:DP:GQ:PL 0/1:18,12:30:99:208,0,455 1/1:0,29:29:86:795,86,0 1/1:1,40:41:99:1010,110,0

29


Raw Reads (Fastq)
BWA-MEM
Map to Reference
SAM
samtools
Alignment Metrics
Text File
Picard
Sort by Coordinate, Convert to BAM
BAM
Picard
Mark Duplicates
BAM
Picard
Build BAM Index
BAI
GATK
Base Quality Score Recalibration
recal_data.table
post_recal_data.table
GATK
Apply Recalibration
BAM
GATK
Variant Calling
VCF
GATK
Extract SNPs
Extract Indels
VCF
GATK
Filter SNPs
Filter Indels
VCF
SnpEFF
Predict Variant Effects
VCF, TXT, HTML

30



Individual quality scores (blue bars) for each position in a single read. The horizontal blue line represents the Q20 phred score value

31

¿Por qué nos importan las puntuaciones de calidad?

- Los algoritmos de llamada variante se basan en la puntuación de calidad asignada a las llamadas base individuales
- Nos dice cuánto podemos confiar en esa observación concreta para informarnos sobre la verdad biológica del yacimiento
- Si tenemos una llamada de base con una puntuación de calidad baja, significa que no estamos seguros de haber leído bien esa A, y podría ser otra cosa
- Así que no confiaremos tanto en él como en otras bases que tienen mejores cualidades
- Usamos esa puntuación para sopesar la evidencia que tenemos a favor o en contra de una variante existente en un lugar concreto

32

¿Por qué recalibrar?

- Las puntuaciones producidas por las máquinas están sujetas a diversas fuentes de errores técnicos sistemáticos
- Conduce a puntuaciones base de calidad sobreestimadas o subestimadas en los datos.
- Pueden surgir errores debido a la física o la química de cómo funciona la reacción de secuenciación, posiblemente fabricando fallos en el equipo.

33

¿Por qué recalibrar?

La recalibración de puntuaciones de calidad base (BQSR) es un proceso en el que aplicamos aprendizaje automático para modelar empíricamente estos errores y ajustar las puntuaciones de calidad en consecuencia.

34

¿Cómo funciona BSQR?

1. Proporciona a *GATK Base Recalibrator* un conjunto de variantes conocidas.
2. Se analizan todas las lecturas buscando diferencias (*mismatches)* entre la lectura y la referencia, omitiendo aquellas posiciones que se incluyen en el conjunto de variantes conocidas (del paso 1).
3. Se calculan estadísticas para las diferencias identificadas en el paso 2 en función de los puntajes de calidad informados, la posición en la lectura, el contexto de secuenciación (por ejemplo, nucleótido anterior y actual).
4. Con base en las estadísticas calculadas en el paso 3, se asigna un puntaje de calidad empírico a cada diferencia, sobrescribiendo el puntaje original.

35

Variant annotations are the "features" of the model

VCF record for an A/G SNP at 22:49582364

```
22 49582364      .      A      G      198.96   .
   AC=3;
   AF=0.50;
   AN=6;
   DP=87;
   MLEAC=3;
   MLEAF=0.50;
   MQ=71.31;
   MQ0=22;
   QD=2.29;
   SB=-31.76
   GT:DP:GQ    0/1:12:99    0/1:11:89    0/1:28:37
```

INFO field

AC	No. chromosomes carrying alt allele	MLEAF	Max likelihood AF
AN	Total no. of chromosomes	MQ	RMS MAPQ of all reads
AF	Allele frequency	MQ0	No. of MAPQ 0 reads at locus
DP	Depth of coverage	QD	QUAL score over depth
MLEAC	Max likelihood AC		

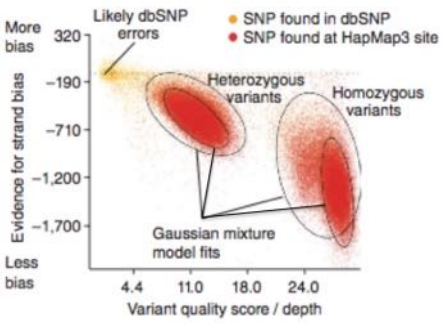
Note that VQSR will only look at INFO annotations;

36

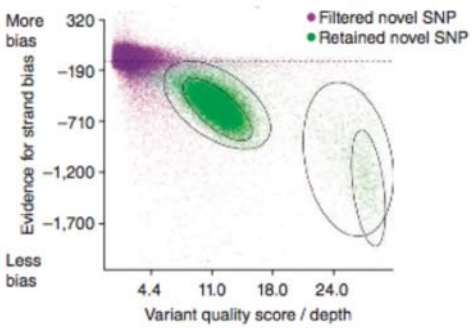
Two steps: (1) train a model then (2) apply to callset

Basic idea: training on high-confidence known sites to determine the probability that other sites are true

(1) Train model using HapMap

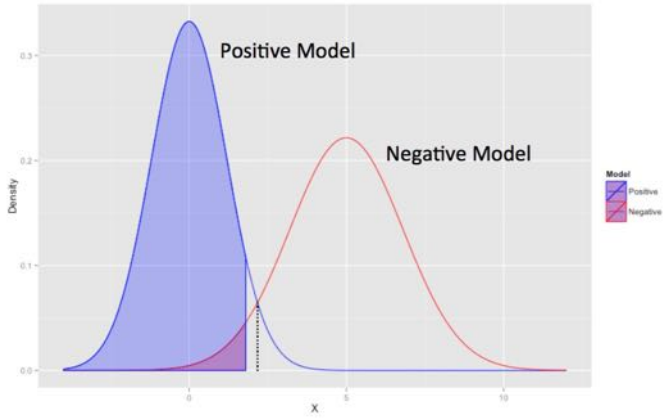


(2) Apply model to callset



37

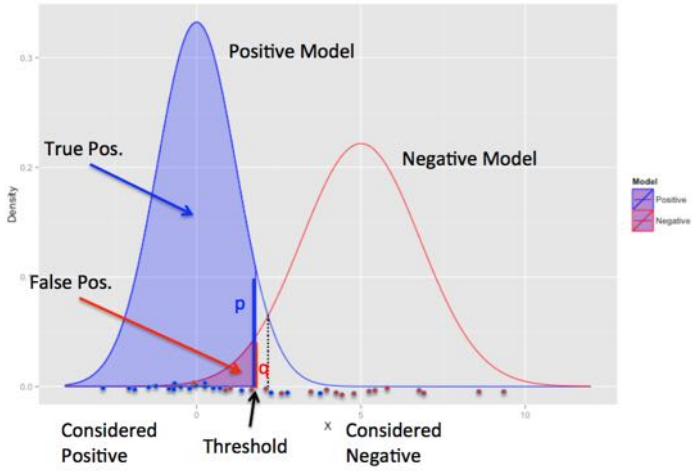
There are in fact two components to the model



- A **negative model** is also built during training
- It represents the probability of variants to be **false positives**

38

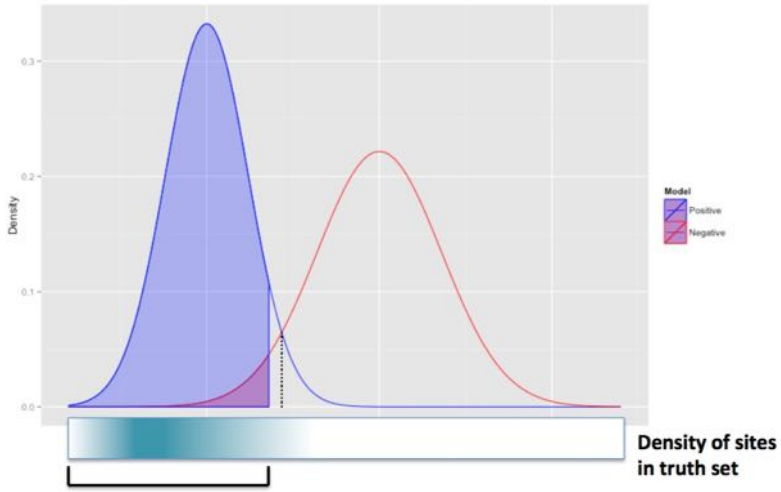
The VQSLOD threshold is a tradeoff between TP and FP



VQSLOD(x) = Log(p(x)/q(x)) (VQSLOD is distinct from QUAL!)

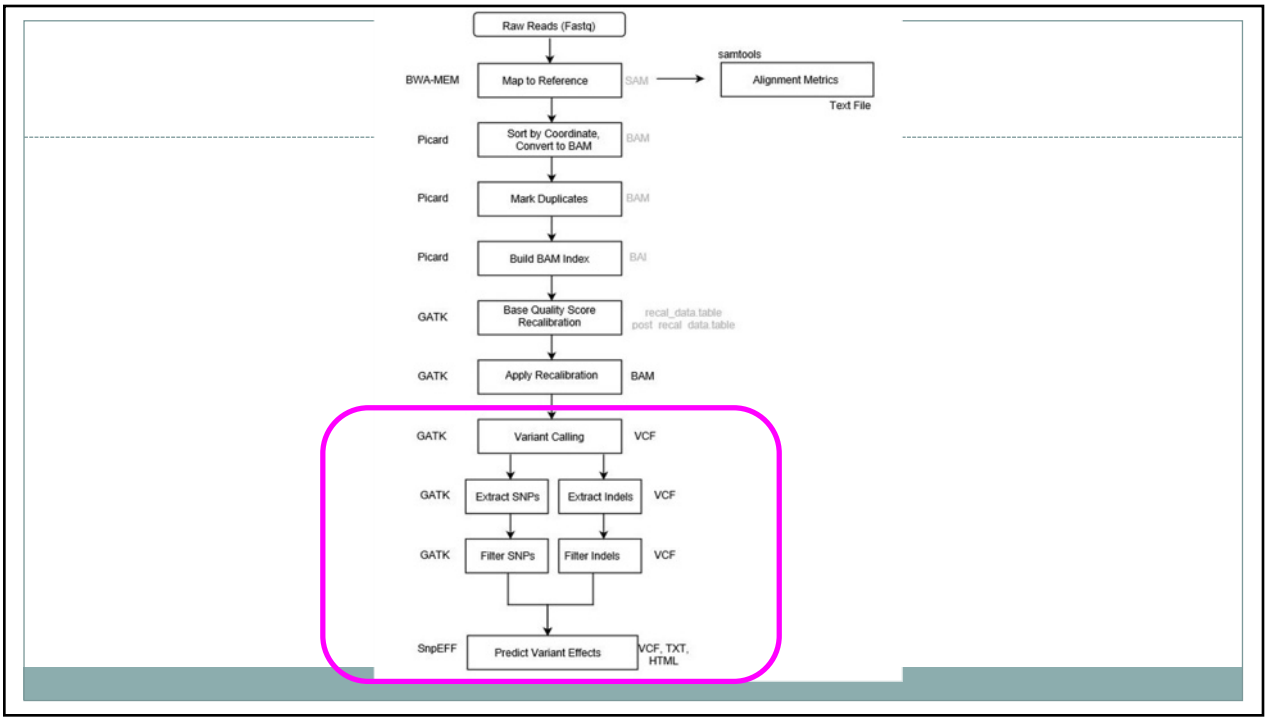
39

We set the threshold based on **sensitivity to truth data**



What threshold do we need to set to capture X % of the sites in the truth set?

40



41

1) Llamado de variantes (variant calling)

- Usamos la herramienta GATK HaplotypeCaller
- Este paso está diseñado para maximizar la sensibilidad y minimizar los falsos negativos, es decir, no identificar variantes reales
- Crea un único archivo con SNPs e indels
- Extraemos cada tipo de variante en su propio archivo para poder procesarlas individualmente

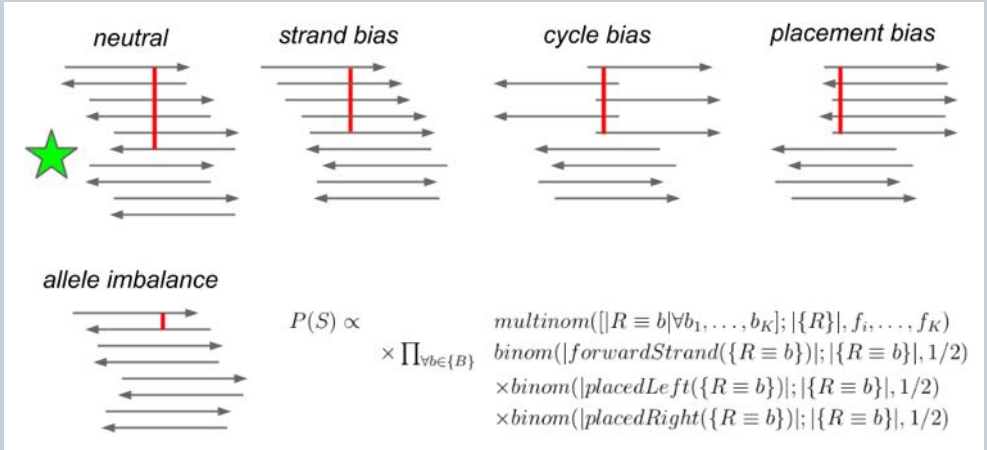
42

2) Filtrado de variantes (Filter Variants)

- El primer paso está diseñado para maximizar la sensibilidad y, por tanto, es muy permisivo a la hora de llamar variantes
- Bueno porque minimiza la posibilidad de perderse variantes reales
- Pero significa que necesitamos filtrar el conjunto de llamadas en bruto para reducir la cantidad de falsos positivos
- Es importante para obtener el conjunto de llamadas de la más alta calidad posible

43

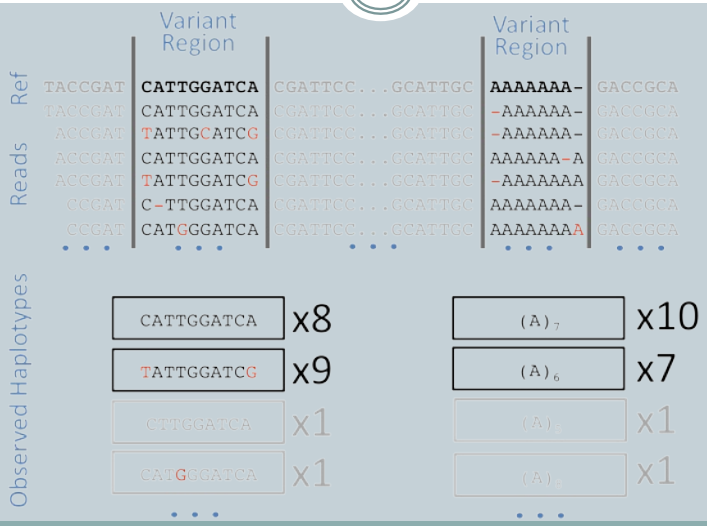
Sesgos de variantes detectadas



https://ekg.github.io/2015/12/08/How-to-freebayes

44

Freebayes – Llamador de variantes basado en haplotipos



https://github.com/freebayes/freebayes

45

3) Annotation

- Nosotros usamos SnpEff
- Anota y predice los efectos de las variantes sobre los genes
  - Codon changes
  - Amino acid changes
  - Genomic region
  - Functional effect (silent, missense)
- SnpEff tiene bases de datos preconstruidas para miles de genomas

46

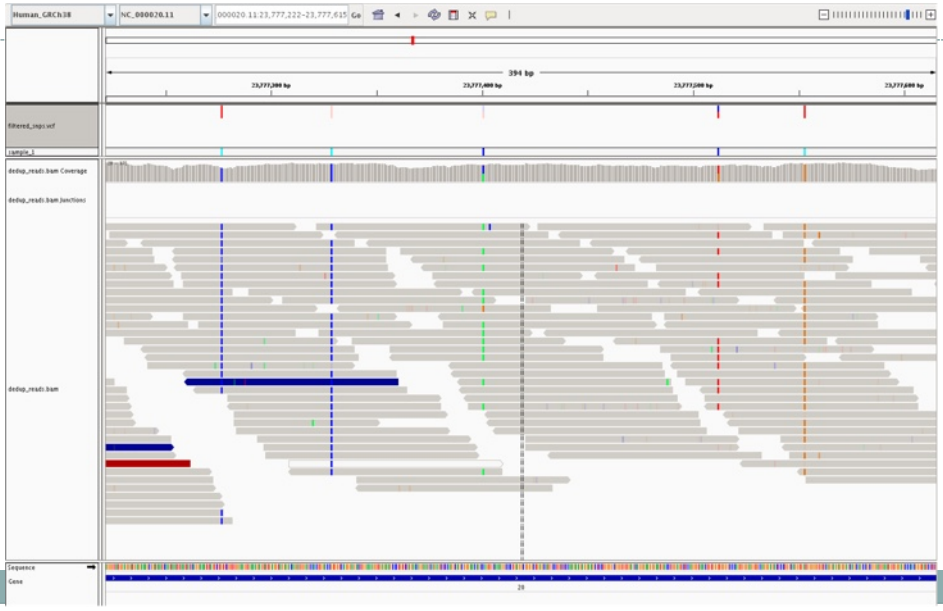
Archivo VCF

```
##fileformat=VCFv4.0
##fileDate=20090805
##source=myImputationProgramV3.1
##reference=1000GenomesPilot-NCBI36
##phasing=partial
##INFO=<ID=NS,Number=1,Type=Integer,Description="Number of Samples With Data">
##INFO=<ID=DP,Number=1,Type=Integer,Description="Total Depth">
##INFO=<ID=AF,Number=.,Type=Float,Description="Allele Frequency">
##INFO=<ID=AA,Number=1,Type=String,Description="Ancestral Allele">
##INFO=<ID=DB,Number=0,Type=Flag,Description="dbSNP membership, build 129">
##INFO=<ID=H2,Number=0,Type=Flag,Description="HapMap2 membership">
##FILTER=<ID=q10,Description="Quality below 10">
##FILTER=<ID=s50,Description="Less than 50% of samples have data">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype Quality">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Read Depth">
##FORMAT=<ID=HQ,Number=2,Type=Integer,Description="Haplotype Quality">
#CHROM POS     ID        REF ALT    QUAL FILTER INFO                              FORMAT      NA00001        NA00002        NA00003
20     14370   rs6054257 G   A      29   PASS   NS=3;DP=14;AF=0.5;DB;H2           GT:GQ:DP:HQ 0|0:48:1:51,51 1|0:48:8:51,51 1/1:43:5:.,.
20     17330   .         T   A      3    q10    NS=3;DP=11;AF=0.017               GT:GQ:DP:HQ 0|0:49:3:58,50 0|1:3:5:65,3   0/0:41:3
20     1110696 rs6040355 A   G,T    67   PASS   NS=2;DP=10;AF=0.333,0.667;AA=T;DB GT:GQ:DP:HQ 1|2:21:6:23,27 2|1:2:0:18,2
2/2:35:4
20     1230237 .         T   .      47   PASS   NS=3;DP=13;AA=T                   GT:GQ:DP:HQ 0|0:54:7:56,60 0|0:48:4:51,51 0/0:61:2
20     1234567 microsat1 GTCT G,GTACT 50   PASS   NS=3;DP=9;AA=G                   GT:GQ:DP    0/1:35:4       0/2:17:2       1/1:40:3
```

http://www.internationalgenome.org/wiki/Analysis/vcf4.0/

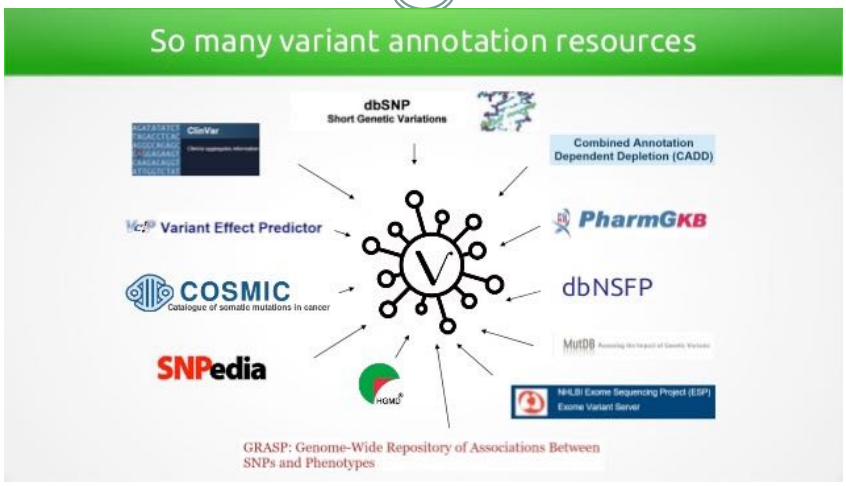
47

4) Visualization - IGV



48

Variant Annotation



49

Variant Annotation: SnpEff

- Herramienta de anotación y predicción de efectos de variantes. Anota y predice los efectos de variantes genéticas (como cambios en aminoácidos).
- Se calculan muchos efectos: como SYNONYMOUS_CODING, NON_SYNONYMOUS_CODING, FRAME_SHIFT STOP_GAINED solo por nombrar algunos.

50

SnpEff: Bases de datos públicas

- **Bases de datos ENCODE** son soportadas por SnpEff (mediante archivos BigWig proporcionados por el proyecto ENCODE).
- **Epigenome Roadmap** proporciona conjuntos de datos que pueden usarse con SnpEff.
- Predicciones de sitios de unión a **factores de transcripción de TFBS**. Los datos de motivos utilizados en estas anotaciones son generados por los proyectos de Jaspar y ENSEBML
- **Base de datos NextProt** puede utilizarse para anotar dominios proteicos así como sitios funcionales importantes en una proteína (por ejemplo, sitio de fosforilación)

51

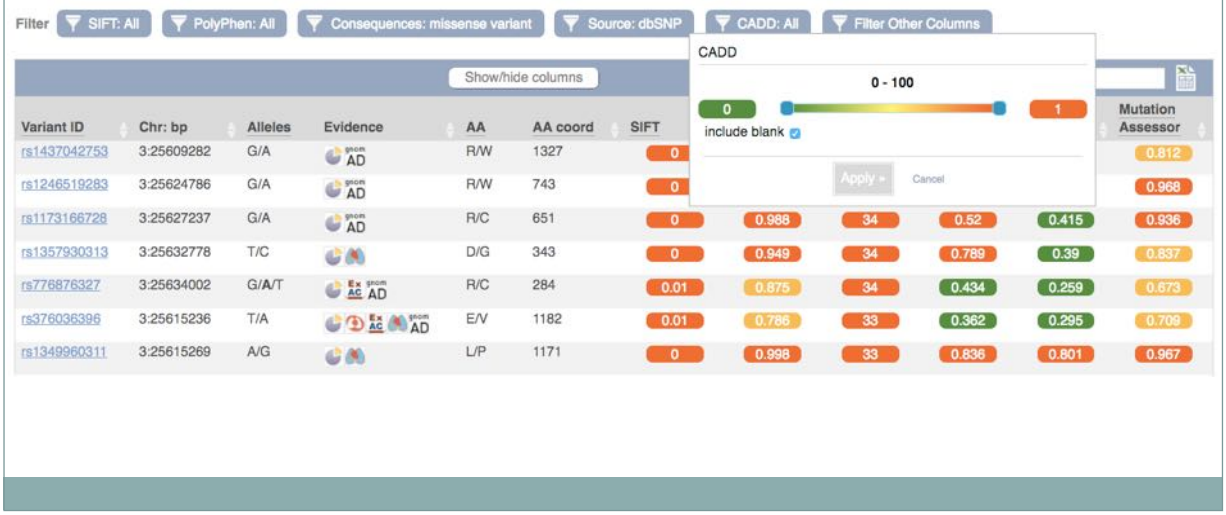
CADD - Combined Annotation Dependent Depletion

- Puntaje que integra múltiples anotaciones en una métrica contrastando variantes que sobrevivieron a la selección natural con mutaciones simuladas
- Generalmente, se considera que:
  - Puntuaciones CADD mayores o iguales a 20 son sugestivas de un efecto patogénico importante, ya que corresponden al 1% más dañino de todas las variantes posibles en el genoma humano.
  - Puntuaciones entre 10 y 20 indican variantes con un probable efecto funcional o moderadamente perjudicial.
  - Valores por debajo de 10 suelen considerarse variantes benignas o poco dañinas.

https://cadd.gs.washington.edu/

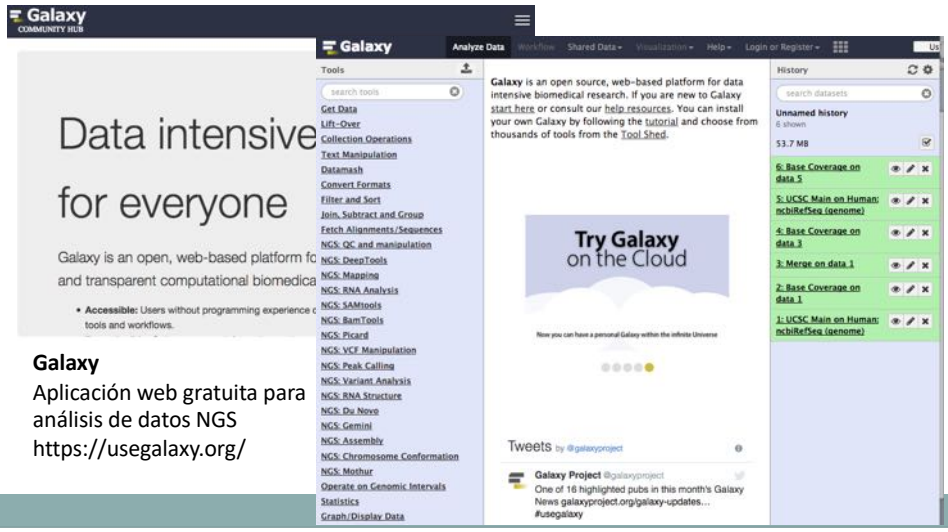
52

Puntajes CADD



53

Software Libre



Galaxy
Aplicación web gratuita para análisis de datos NGS
https://usegalaxy.org/

54

Resources in NGS data analysis

Public forums:

SEQanswers
the next generation sequencing community

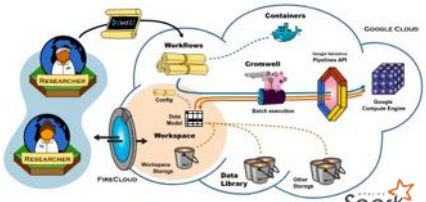
Bioconductor
OPEN SOURCE SOFTWARE FOR BIOINFORMATICS

BioBits: A Blog about bioinformatics

Biostars
BIOINFORMATICS EXPLAINED

BROAD INSTITUTE **FireCloud**

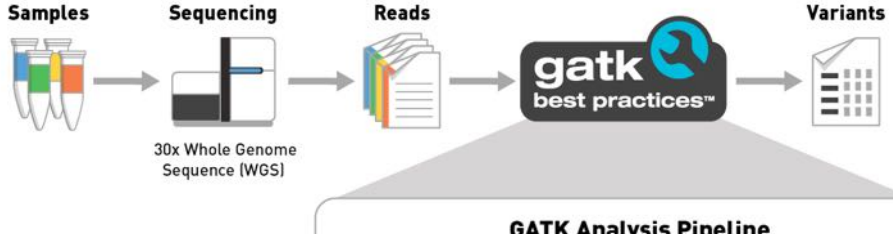
An open platform for secure and scalable analysis on the cloud



Google Cloud



55



	2016	2017	2018 (March)
# of Whole Genomes Analyzed	900	900	900
Total Compute Cost	$40,500	$12,150	$4,500
Cost per Genome Analyzed	$45	$13.50	$5

56